

Clasificación de Marcha Patológica mediante Redes Recurrentes y Mecanismos de Self-Attention a partir de Esqueleto 3D

Weimar Andres Arenas Gonzalez
Curso Fundamentos de Deep Learning
22/03/2026

1. Contexto de aplicación

El análisis de la marcha humana es una herramienta clave en el diagnóstico clínico de trastornos neurológicos y musculoesqueléticos, patologías como Parkinson, daño cerebral, accidentes cerebrovasculares o lesiones articulares producen alteraciones características en los patrones de marcha.

Tradicionalmente, este análisis requiere sistemas costosos (VICON, OptiTrack); sin embargo, sensores de profundidad como Microsoft Kinect v2 permiten capturar esqueletos 3D de bajo costo, este proyecto aplica técnicas de Deep Learning para clasificar 1 marcha normal y 5 patológicas: **Antálgica** (dolor), **rígida** (stiff-legged), **oscilante** (lurching), **steppage** (pie caído) y **Trendelenburg** (debilidad de glúteo medio).

2. Objetivo de Machine Learning

Dado un segmento de **50 frames** de coordenadas 3D de 25 articulaciones capturadas por Kinect v2, se busca predecir la clase de marcha entre 6 categorías (clasificación multiclase sequence-to-one), cada frame contiene 75 features (25 joints $\times$ 3 coordenadas x, y, z), se buscará explorar durante el proyecto las siguientes técnicas:

- **RNN simple.**
- **LSTM y GRU de múltiples capas**
- **LSTM/GRU Bidireccional:** Capturando dependencias pasadas y futuras de la secuencia.
- **Transformer / Self-Attention:** Aplicando el mecanismo de auto-atención sobre las secuencias de esqueleto, permitiendo al modelo ponderar la importancia de cada frame y cada articulación

3. Dataset

Se utilizará el **GIST Pathological Gait Dataset** (Jun et al., 2020), publicado en IEEE Access y compartido en: github.com/kooksung/pathological_gait_datasets

Característica	Detalle
Tipo de datos	Secuencias temporales de coordenadas 3D (25 articulaciones $\times$ 3 ejes = 75 features/frame)
Sensor	6 cámaras Kinect v2 calibradas con marcadores ArUco
Sujetos	10 personas sanas simulando marchas bajo supervisión estricta
Secuencias	7,200 clips (10 $\times$ 6 tipos $\times$ 20 repeticiones $\times$ 6 Kinects); 7,157 usables (50 frames c/u)
Tamaño en disco	< 200 MB (archivos CSV ligeros)
Formato	CSV: time, joint0_x, joint0_y, joint0_z, ..., joint24_x, joint24_y, joint24_z

Distribución de Clases

Cada una de las 6 clases (Normal, Antálgica, Rígida, Oscilante, Steppage, Trendelenburg) contiene exactamente 1,200 secuencias (16.67% cada una), esto simplifica la elección de métricas y elimina la necesidad de técnicas de balanceo.

4. Métricas de Desempeño

4.1 Métricas de Machine Learning

- Accuracy global (válida al estar las clases balanceadas).
- Sensibilidad, Especificidad y Precisión por clase (siguiendo la metodología de Jun et al., 2020, Table 4 del paper).
- Matriz de confusión para identificar confusiones entre tipos de marcha similares.
- Leave-One-Subject-Out CV (LOSO-CV): consistente con el paper original, para evaluar generalización a sujetos no vistos.

4.2 Métricas de Negocio / Clínicas

- **Sensibilidad por clase patológica:** Minimizar falsos negativos en detección de marchas anormales.
- **Tiempo de inferencia y tamaño del modelo:** Relevante para despliegue en entornos de bajo costo.

5. Referencias y Resultados Previos

Resultados reportados por Jun et al. (2020) sobre el dataset GIST, utilizando LOSO-CV:

Modelo	Accuracy	Referencia	Notas
GRU (4 capas)	90.13%	Jun et al. 2020	Todas las articulaciones
GRU (solo piernas)	93.67%	Jun et al. 2020	Mejor resultado reportado
LSTM (4 capas)	87.25%	Jun et al. 2020	Todas las articulaciones
RNN básica	86.23%	Jun et al. 2020	Todas las articulaciones
CNN 1D	86.65%	Jun et al. 2020	Filtro conv. + FC
ST-GCN + Atención	>95%	Kim et al. 2022	Graph Conv + Attention
Bi-LSTM	90.75%	Guo et al. 2020	Dataset similar, 6 tipos

Hallazgos clave del paper: Las articulaciones de piernas son las más relevantes (excluir brazos mejora +2%); las articulaciones de brazos generan ruido por variabilidad en balanceo entre sujetos; el optimizador Adam fue el más efectivo.

Objetivo del proyecto: Replicar y superar los resultados con LSTM/GRU, y explorar si un modelo basado en Self-Attention (Transformer) puede alcanzar o superar el 93.67% reportado, aprovechando la capacidad de ponderar simultáneamente todos los frames sin la limitación secuencial de las RNN.

6. Requerimientos Computacionales

Aspecto	Detalle
RAM	Aproximadamente 2 GB para entrenamiento, dataset en CSV < 200 MB, ~300–500 MB en memoria tras preprocesamiento.

GPU	No requerida, secuencias de 50×75 son ligeras; RNN/LSTM/Transformer pequeños entrenan eficientemente en CPU.
Framework	TensorFlow/Keras.
Tiempo estimado	5–20 min/modelo en CPU, batch pequeño, 500 epochs.

7. Bibliografía

1. Jun, K., Lee, Y., Lee, S., Lee, D. & Kim, M.S. (2020). Pathological Gait Classification Using Kinect v2 and Gated Recurrent Neural Networks. IEEE Access, 8, 139881–139891. DOI: 10.1109/ACCESS.2020.3013029
2. Jun, K., Lee, D.W., Lee, K., Lee, S. & Kim, M.S. (2020). Feature Extraction Using an RNN Autoencoder for Skeleton-based Abnormal Gait Recognition. IEEE Access, 8, 19196–19207.
3. Kim, J., Seo, H., Naseem, M.T. & Lee, C.S. (2022). Pathological-Gait Recognition Using Spatiotemporal Graph Convolutional Networks and Attention Model. Sensors, 22(13), 4863.
4. Khokhlova, M., Migniot, C., Morozov, A., Sushkova, O. & Dipanda, A. (2019). Normal and pathological gait classification LSTM model. Artif. Intell. Med., 94, 54–66.
5. Lee, D.W., Jun, K., Lee, S., Ko, J.K. & Kim, M.S. (2019). Abnormal gait recognition using 3D joint information of multiple Kinects system and RNN-LSTM. IEEE EMBC, pp. 542–545.
6. Vaswani, A. et al. (2017). Attention Is All You Need. NeurIPS. (Fundamento teórico del Transformer).